

데이터 고급 통계 분석 실무 활용

AI로 통계 분석의 난이도를 낮춘다 — 외부망에서 배우고, 폐쇄망 STATA로 현업에 적용

데이터	대상	핵심 도구	최종 산출물
WDI 패널 · 217국×23년	Python·STATA 입문 동료	생성형 AI · Python · STATA	폐쇄망 STATA 코드 꾸러미

오늘 우리는 —

회귀 · 교차표 · 패널 분석을 **직접** 돌립니다.
단, 문법은 한 줄도 **외우지** 않습니다.



오늘의 약속

강의가 끝나면 폐쇄망 STATA에서 바로 돌아가는 코드 꾸러미를 손에 쥐고 돌아갑니다.

우리 회사엔 **두 개의 환경**이 있다

이 강의의 전제 — '배우는 곳'과 '일하는 곳'이 분리되어 있다.

외부망 · 학습·탐색

여기서 배우고 만든다

- ✓ 생성형 AI 사용 가능 (코드 생성)
- ✓ Python 사용 가능
- ✓ 인터넷 연결 · 실습 제약 없음



코드로
변환·반입

폐쇄망 · 현업·실행 (air-gapped)

여기서 돌아간다

- ✗ 인터넷 X · AI X · Python X
- STATA O ← 실제 업무는 여기서
- 결과물은 여기서 실행된다

전략 · AI·Python으로 외부망에서 빠르게 배워 → 폐쇄망 STATA에서 그대로 돌아가는 코드 꾸러미로 변환해 들고 돌아간다

이 강의의 두 축

난이도는 **AI**가 낮추고, 신뢰는 **인간**이 높인다.

축 ①

AI가 난이도를 낮춘다

- 1 **설계** — 무엇을·왜 분석할지 · 사람
- 2 **생성** — 코드를 AI에게 시킨다 · AI·외부망
- 3 **검증·해석** — 3대 무기로 · 사람

축 ②

최종 판단은 인간 — 3대 무기



시각화 — 그림으로 보면 오류가 보인다



도메인 지식 — "그럴 리 없다"를 안다



동료 회람 — 여러 눈으로 함께 잡는다

"AI가 분석을 **쉽게** 만들어도, **맞게** 만드는 건 여전히 인간이다."

01

Python과 STATA, 무엇이 다른가

전용 소프트웨어 vs 범용 언어 — 그리고 AI가 바꾼 게임

STEP 1

한 문장으로 끝내는 차이

STEP 2

7가지 실제 차이

STEP 3

AI가 게임을 바꿨다

한 문장으로 끝내는 차이

오늘 다룰 모든 차이는 이 한 문장에서 파생된다. 외울 건 이것 하나뿐.

STATA

통계를 위해 태어났다

통계 분석 전용 소프트웨어

계량경제학자가 만든 **완성된 도구**. 통계 작업엔 특화돼 간결하다.
단, 그 바깥(웹·자동화·ML)은 약하다.

Python

통계를 (나중에) 배웠다

범용 프로그래밍 언어

통계는 **라이브러리(부품)**를 엮어서 한다. 수집·자동화·AI 무엇이든.
단, 부품을 조립할 줄 알아야 한다.

 **비유** — STATA는 잘 만든 **전통 공구** 한 자루, Python은 그 공구를 만들 수도 있는 **공방** 전체. 못 박을 땐 공구가, 가구를 짤 땐 공방이 필요하다.

같은 회귀, 두 세계

"소득이 높을수록 기대수명이 길까?"(Preston 곡선) — 똑같은 회귀분석을 양쪽으로.

STATA 동사 하나로 결과까지 직행

```
regress life_exp log_gdp
```

통계 전용 도구라서 단 한 줄. 계수·표준오차·p값· R^2 가 출판 수준 표로 바로 나온다.

Python 불러오고·만들고·맞추고·출력

```
import statsmodels.formula.api as smf

model = smf.ols("life_exp ~ log_gdp", data=df).fit()
print(model.summary())
```

범용 언어라 라이브러리를 조립한다. 그만큼 통계 바깥도 무엇이든 자유롭다.

→ 그런데 나오는 계수와 p값은 완전히 똑같다. 길이가 다를 뿐, 정답은 하나다.

그 한 문장에서 갈라지는 7가지 차이

근본 차이(전용 SW vs 범용 언어)가 현장에서 어떻게 나타나는가.

차이	STATA · 전용 SW	Python · 범용 언어
데이터 방식	한 데이터셋이 작업공간에 상주	이름 붙은 객체 여러 개 동시 조작
명령 vs 함수	동사형 명령어 — 문장처럼 읽힘	함수·메서드 조합 — 유연하나 조립
통계 출력	출판 수준 표준 표 기본 제공	직접 가공 · 무한 커스터마이징
가능 범위	통계·계량 안에서 깊다	수집·API·ML·텍스트·배포까지
비용	상업용 유료 라이선스	완전 무료 오픈소스
재현성	.do + .log — 계량 저널 표준	노트북 · 스크립트 + Git
학습곡선 ★	낮다 — 한 줄로 고급 분석, 입문친화	높다 → AI가 무력화

★ 7번 학습곡선을 기억해 두세요 — 잠시 뒤 이 차이를 **무력화**시킵니다.

누가, 어디서 쓰나 — 분야 지도

도구는 진공에 있지 않다. 각자의 '사용자 부족(部族)'이 있다.

STATA의 세계

- 경제학 · 계량경제
- 보건경제 · 역학
- 정책평가 · 임팩트평가(RCT)
- World Bank · 학계 · 국제개발 연구

Python의 세계

- 데이터과학 · 머신러닝
- 테크 · 엔지니어링
- 자동화 · 데이터 파이프라인
- 점점 → 개발협력 · 평가로 확산

능력 차이가 아니라 '생태계 관습'이다 — RCT·임팩트평가도 Python으로 다 된다. 다만 관행상 STATA 보고서가 많고, 수집·대시보드는 Python이 흔할 뿐. 둘 다 읽고 쓰면 현장 전체가 보인다.

반전 — AI가 게임을 바꿨다

입문자의 가장 큰 장벽은 늘 **문법**이었다. 그런데 문법은 AI가 대신 짤다.

예전 도구 선택 = "내가 이 문법을 짤 수 있는가?"

→ 입문자는 쉬운 STATA로 도망쳤다.



지금 도구 선택 = "이 작업에 어느 생태계가 맞는가?"

→ AI가 양쪽 문법을 다 짜주니, 일에 맞는 도구를 고른다.

문법이라는 입장료를 AI가 대신 낸다 → 첫 시간부터 회귀·교차표·패널로 직행. "둘 다 입문이지만 오늘 **중급으로 도약**한다."

도입 한 장 요약 — 사진 찍어두세요

한 줄로 정리하면 이렇다.

	STATA	Python
한마디	통계 전용 소프트웨어	범용 프로그래밍 언어
잘하는 것	통계 분석에 특화 — 명령이 간결	수집·자동화·ML·배포까지 무엇이든
비용	유료	무료
학습곡선 ★	낮음	높음 → AI가 무력화
원업 환경	폐쇄망에 설치됨 (실행)	외부망 학습·비교용 (폐쇄망엔 없음)

오늘의 전략 · 외부망에서 AI로 배우고 → 폐쇄망 STATA 코드 꾸러미로 변환 → 인간이 검증한다

02

데이터 소개 + AI로 첫 분석

분석 전에 **재료**부터 — 데이터를 알아야 결과가 말이 되는지 판단한다.

📁 실습 파일 — notebooks/01_load_clean.ipynb · stata/01_load_clean.do

STEP 1

WDI 데이터 감 잡기

STEP 2

AI 분석 의뢰 프롬프트

STEP 3

불러오기·정제 시연

WDI란 무엇인가

World Bank WDI(World Development Indicators) — 세계은행 대표 개발지표 DB. 보고서의 '**1인당 GDP**'·'**기대수명**' 출처가 십중팔구 여기다. 오늘은 그 진짜 데이터를 직접 만진다.

200+

개국 커버리지

전 세계 거의 모든 나라

1,486

개 지표

소득·보건·교육·인구·환경

1960~

현재까지

60년+ 시계열 · 공개·무료



직접 받기

databank.worldbank.org/source/world-development-indicators · data.worldbank.org — 강의 중 실제 페이지를 열어 데이터셋을 보여주세요.

오늘 우리가 쓰는 데이터

WDI에서 핵심 지표만 뽑은 국가×연도 패널 — 한 행 = 한 국가의 한 해.

패널 데이터

217개국

23년 · 2000~2022


4,991행

같은 나라를 여러 해 추적 → 모듈 4 고정효과
의 토대.

변수	의미	단위·예시
economy_name	국가코드 · 국가명	KOR · Korea
year	연도	2000~2022
region_name	지역	7개 권역
income_name	소득그룹	고/상위중/하위중/저
gdp_pc ★	1인당 GDP	현재 US\$
life_exp ★	기대수명	세(출생 시)
under5_mort ★	5세 미만 사망률	1,000명당
pop ★	총인구	명
prim_enroll ★	초등 취학률	% (100%+ 가능)

개발의 스펙트럼 — Preston 곡선

2021년 210개국. 한 점 = 한 나라. 점에 마우스를 올려보세요.



Preston 곡선

소득과 기대수명의 관계(S. Preston, 1975). 저소득 구간에선 소득이 조금만 늘어도 수명이 **급증**, 고소득에선 **완만**해진다.



에티오피아

\$893 · 65세



베트남

\$3,704 · 74세



한국

\$37,518 · 84세

'진짜 데이터'라서 생기는 것들

합성 데이터엔 없는 현실. 그리고 이게 모듈 2 정제와 모듈 5 검증의 진짜 소재.



결측이 있다

일부 국가·연도에 값이 빠져 있다.

under5_mort 약 10%, **prim_enroll** 약 23%.



분류에 빈칸도

일부 국가는 소득그룹이 '**Not classified**'.

"진짜 데이터는 늘 손이 간다."



어떻게 받았나

World Bank API를 Python **wbgapi**로 수집. → 모듈 4-B에서 **직접** 해본다.

결측·빈칸이 보여도 당황 마세요. **진짜 데이터**라서 그런 거고, 그걸 다루는 게 실무다. **오히려 깨끗하기만 한 데이터가 더 수상하다.**

AI와 대화로 분석을 설계한다

"pandas로 짜줘" 같은 정형 프롬프트는 이제 구식 — AI가 알아듣고, 모호하면 **먼저 되묻는다**.



1인당 GDP는 왜도가 크니 **로그변환**할까요? 결측 국가는 **제외**할까요?

WDI 데이터로 소득이 기대수명에 주는 영향을 보고 싶어.



예전

정형 프롬프트를 외웠다(역할·데이터·도구...)



네 — 양쪽 코드와 결과 읽는 법, 제가 가정한 것까지 정리했습니다. ✓

응, 로그변환하고 결측 제외. STATA랑 Python 둘 다 줘.



지금

목표만 말하면 AI가 되묻고 함께 완성

변하지 않는 핵심 — 무엇을·왜 분석할지(설계)와 결과 검증은 사람. AI는 구현과 되물음을 맡는다.

★ 가장 중요

폐쇄망 실행용 프롬프트

이 한 가지가 외부망 학습을 현업 실행으로 잇는다.

💬 AI에게 이렇게 시킨다

"이 STATA 코드를 추가 패키지(SSC) 없이 **base STATA**만으로, 인터넷 없이 오프라인에서 돌아가게 짜줘. 경로·변수명은 파일 맨 위에 모아 한 곳만 바꾸면 되게."

✓ SSC 패키지 불필요

✓ 인터넷 없이 오프라인

✓ STATA 19 MP (우리 환경)

WDI 불러오기·정제를 양쪽으로

로드 → 결측 확인 → 소득 음수 점검 → 로그변수 → 요약. 같은 작업, 두 도구.

Python · pandas

```
df = pd.read_csv("wdi_panel.csv")
df.info()
df.isna().sum()          # 결측 현황
work = df.dropna(subset=["gdp_pc", "life_exp"])
work["log_gdp"] = np.log(work["gdp_pc"])
```

STATA · .do

```
import delimited "wdi_panel.csv", clear
describe
misstable summarize      // 결측 현황
drop if missing(gdp_pc, life_exp)
gen log_gdp = ln(gdp_pc)
```

첫 검증 — 행 수가 맞나? 결측은 어떻게 처리했나? 단위는 맞나? AI가 임의로 한 가정을 들춰낸다.

→ 01_load_clean.do

03

같은 분석을 Python과 STATA로

대표 분석 3종을 양쪽으로 — 숫자가 같으면 신뢰, 다르면 하나가 틀린 것.

📁 실습 파일 — notebooks/02_core_analysis.ipynb · stata/02_crosstab · 03_group_compare · 04_regression.do

분석 ①

교차표 — 지역×소득그룹

분석 ②

t검정 · ANOVA

분석 ③

회귀 — Preston 곡선

① 교차표 — 지역 × 소득그룹

🔍 연구질문 — 각 지역에 어느 소득그룹 나라가 몇 개 있는가? (국가 단위)

Python

```
countries = df.drop_duplicates("economy")
# 국가당 1행
pd.crosstab(countries["region_name"],
            countries["income_name"])
```

STATA

```
bysort economy (year): keep if _n==1
// 국가당 1행
tabulate region_name income_name
```

→ 해석 — 저소득국 다수가 사하라이남에, 고소득국은 유럽·동아태 등에 분포. (지역·소득은 국가 속성이라 국가당 1행으로 집계)

② 집단 비교 — t검정 · ANOVA

🔍 연구질문 — 사하라이남 vs 그 외(2집단)? · 소득그룹 4개 사이(3집단+)?

Python · scipy

```
from scipy import stats
# 2집단 - Welch t검정
stats.ttest_ind(ssa, rest, equal_var=False)
# 3집단+ - 일원 ANOVA
stats.f_oneway(*groups)
```

STATA

```
* 2집단 - Welch t검정
ttest life_exp, by(ssa) unequal

* 3집단+ - 일원 ANOVA
oneway life_exp income_n, tabulate
```

두 집단이면 t검정, 세 집단 이상이면 ANOVA. 분산이 다를 수 있어 t검정은 **Welch(unequal)**를 쓴다.

결과 읽기 — 무엇이 유의한가

p값은 '우연일 가능성'. 0.05보다 작으면 통계적으로 유의하다.

t검정 · 2집단

사하라이남 vs 그 외

두 집단의 기대수명 평균 차이가 유의하다. $p < 0.05$

ANOVA · 4집단

$F = 1877$


소득그룹 4개 사이 기대수명 차이 매우 유의.

소득그룹별 평균 기대수명 격차

저소득 ~58세 → 고소득 ~78세

③ 회귀 설계 — 왜 로그변환?

회귀 전에 사람이 내리는 판단. 버튼으로 분포를 바꿔보라 — 왜도가 사라진다.



왜도(skewness)

≈ 2.9

한쪽으로 크게 쏠림 — 평균이 분포를 잘 대표하지 못한다.

AI는 이것 자동으로 안 할 수 있다. "로그를 취할까?"는 데이터를 아는 사람의 판단 — 설계는 사람 몫.

③ 회귀 코드와 결과 — Preston 곡선

🔍 연구질문 — 소득(log)이 기대수명을 얼마나 설명하는가?

Python

```
smf.ols("life_exp ~ log_gdp", data=df).fit()
```

STATA

```
regress life_exp log_gdp
```

소득 계수

4.59

양수 · 유의

설명력 R^2

0.68

설명력 높음

→ 해석 — 소득↑ 기대수명↑. Python·STATA 계수· R^2 가 정확히 일치.

숫자는 같다. 출력 모양만 다르다.

두 도구의 결과가 같으면 신뢰, 다르면 하나가 틀린 것 — 이것이 교차검증이다.

지표	Python	STATA
회귀 계수 (log_gdp)	4.59	4.59
설명력 R ²	0.68	0.68
ANOVA F	1877	1877



세 지표 모두 일치 → 신뢰할 수 있다. 도구는 달라도 정답은 하나.

04

AI로 고급 분석까지 인과추론 + 머신러닝

비교로 끝내지 않는다 — 진짜 고급 기법 두 가지를 실제로 돌린다.

📁 실습 파일 — [notebooks/03_panel_fe.ipynb](#) · [04_python_strength.ipynb](#) · [stata/05_panel_fe.do](#)

4-A · STATA

이원 고정효과 (인과추론)

4-B · Python

수집 + 랜덤포레스트 (ML)

4-C

도구 선택은 환경·작업으로

식별의 문제 — 진짜 효과는?

소득과 기대수명은 시간이 지나며 함께 오른다. 단순 회귀는 둘을 혼동(confounding)한다.

소득 → 기대수명 관계에 섞여 있는 두 교란



국가 고유차

제도 · 기후 · 문화 — 나라마다 다르고, 잘 변하지 않는 특성.



전세계 시대추세

기술 발전 · 의료 발달 — 모든 나라가 함께 겪는 시간 효과.

해결 — 고정효과(Fixed Effects)로 이 두 교란을 걷어내고 '소득의 순효과'에 다가간다.

통제할수록 답이 바뀐다

무엇을 통제하느냐에 따라 '소득 계수'가 달라진다 — 교란을 걷을수록 순효과에 근접.

[▶ 단계별로 보기](#)

4.59 → 3.54 → 1.26 · 이것이 **식별의 문제** — 통제를 더할수록 '소득의 진짜 효과'에 근접한다.

이원 고정효과를 양쪽으로

🔍 국가 + 연도를 동시에 통제하면, 소득의 순효과는?

STATA · base STATA

```
encode economy, gen(country_id)
xtset country_id year
xtreg life_exp log_gdp i.year, ///
      fe vce(cluster country_id)
```

Python · statsmodels

```
smf.ols("life_exp ~ log_gdp"
        "+ C(economy) + C(year)",
        data=df).fit()
```

두 도구의 소득 계수가 정확히 일치 — 도구가 달라도 식별 결과는 하나.

계수 1.262

이원 FE = DiD의 엔진

차분-차분(Difference-in-Differences) — 임팩트평가의 표준. 방금 돌린 이원 고정효과가 곧 그 **회귀 구현**이다.

정책효과 = 변화의 차이

처치군의 변화에서 대조군의 변화를 뺀다.

	처치 전	처치 후	변화
처치군	A	B	B-A
대조군	C	D	D-C

$$\text{DiD} = (B-A) - (D-C)$$

개체 FE

나라별 **고유차** 통제 — 대조 비교의 역할

시간 FE

공통 **시대추세** 통제 — 전·후 보정

→ 둘을 동시에 통제한 **이원 FE = 일반화된 DiD**.



KOICA M&E(모니터링·평가) 분석과 바로 연결 — 폐쇄망 base STATA로 실행.

AI가 코드를 짜줘도, 어떤 교란을 통제할지(설계)와 결과 검증은 — **사람 몫**.

Python의 고급 영역 — 수집 + ML

STATA로는 매우 빈약한 두 가지. 외부망 Python에서.


① 라이브 수집 · wbgapi

World Bank API에서 실시간 수집·자동화. 이 강의 데이터 자체가 이렇게 만들어졌다.

```
import wbgapi as wb
wb.data.DataFrame(
    ["NY.GDP.PCAP.CD", "SP.DYN.LE00.IN"],
    ["KOR", "VNM", "ETH"], time=2021)
```

② 랜덤포레스트 · ML

의사결정나무 수백 그루의 앙상블 — 데이터·변수를 무작위로 뽑아 학습해 과적합 ↓, 비선형·상호작용을 자동 포착.



train/test 분할·교차검증으로 정직하게 평가

RF test R^2 0.96 > OLS 0.82

수집·자동화·ML은 Python의 영역. 단, "예측이 잘된다 ≠ 인과" — 도메인 검증 필수.

오늘 못 다룬, 알아두면 좋은 기법

AI에게 이름만 말하면 다 불러온다 — '무엇을 풀지' 고르는 게 핵심.

로지스틱 회귀

분류

예/아니오 같은 이진 결과의 확률을 예측. 예: 빈곤 여부, 사업 성공/실패, 채무불이행.

K-최근접이웃 (K-NN)

분류·예측

가장 가까운 이웃 K개를 보고 판정. 직관적·비모수 — 비슷한 나라들로 결측 추정에도.

서포트벡터머신 (SVM)

분류

두 그룹을 최대 여백으로 가르는 경계를 찾는다. 표본이 적고 고차원일 때 강함.

군집분석 (K-means)

비지도

정답 라벨 없이 비슷한 것끼리 묶는다. 예: 개발 패턴이 닮은 국가 유형화.

분류·예측·군집... 도구는 많다. 호출은 AI가, '무엇을 왜 풀지'와 결과 검증은 사람이.

도구 선택은 '환경·작업'으로

'무료냐 유료냐'가 아니라, '어디서 돌려야 하고 무슨 일이냐'로 고른다.

이럴 땐	도구	이유
폐쇄망에서 바로 실행해야 하는 현업 분석	STATA	현재 우리 폐쇄망 실행 환경
수집·API·자동화·ML·텍스트·시각화·배포	Python	압도적 생태계, 외부망에서
모르겠다	둘 다	AI에게 둘 다 시켜 교차검증

0 5

인간의 검증력 — 3대 무기

AI가 난이도를 낮춰도, 검증은 인간이 더 잘한다. 여러분에게겐 무기가 있다.

📁 실습 파일 — notebooks/05_human_verification.ipynb



시각화 — 그려서 본다




도메인 지식 — 현장을 안다



동료 회람 — 함께 본다

한 데이터, 여러 그림 — 각도를 바꾸면 보인다

같은 오류 데이터(베트남 GDP $\times 1,000$)를 세 방식으로. 어느 그림에서든 된다.



산점도

히스토그램

박스플롯

📍 산점도 — 추세에서 벗어나 오른쪽으로 튼 점

📊 히스토그램 — 분포에서 동떨어진 외딴 막대

📦 박스플롯 — 수염 밖 유일한 이상치(outlier)

한 각도로 안 보여도, 여러 그림으로 그리면 같은 이상치가 거둬 드러난다.

나머지 두 무기 — 도메인 · 회람

AI가 못 가진, 사람만의 강점.

도메인 지식 — 현장을 안다

"베트남이 그 해 세계 최고 소득? 말이 안 된다."

AI에겐 현장의 사실(ground truth)이 없다. **여러분에게겐 있다.**

동료 회람 — 함께 본다

1장 요약을 동료에게 회람 → "이 수치 단위가 이상한데요?"

교차검증 — Python·STATA 숫자가 일치하나? (다르면 하나가 틀린 것)

한 사람(혹은 AI)이 놓친 걸 **여러 눈이 잡는다**. 검증을 통과한 결과만 의사결정 언어로 보고한다.

인간의 3대 무기 — 종합

AI는 빠르지만 보지 못하고, 맥락이 없고, 혼자 일한다.

무기	AI의 약점	인간의 강점
 시각화	숫자만 보고 이상치를 놓침	그림으로 보면 오류가 보인다
 도메인 지식	현장의 사실(ground truth)을 모름	"그럴 리 없다"를 안다
 동료 회람	혼자, 진공 상태에서 답함	여러 눈으로 함께 잡는다

AI로 난이도를 낮추고, 이 세 무기로 신뢰도를 높인다.

AI로 난이도를 낮추고, 인간이 검증한다.

① 설계

무엇을·왜 — 사람

② 생성

코드 — AI·외부망

③ 검증·해석

3대 무기 — 인간

코드 꾸러미 (완성)

github.com/amnotyoung/oda-ai-stats

Colab 노트북 5 · STATA .do 6 · WDI 데이터 · 핸드아웃 — 폐쇄망엔 stata/ + data/ 반
입

다음 학습 경로

내 업무 질문 1개 → 외부망 AI로 설계 → STATA 코드로 변환 → 폐
쇄망 실행